

UNIVERSIDAD SAN FRANCISCO DE QUITO USFQ

Colegio de Ciencias e Ingenierías

**Diseño e implementación de un índice de señales textuales de
acusatoriedad en procesos de compras públicas (GEN) mediante
Procesamiento de Lenguaje Natural**

Gian Martín Tituaña Intriago

Ingeniería en Ciencias de la Computación

Trabajo de fin de carrera presentado como requisito
para la obtención del título de
Ingeniero en Ciencias de la Computación

Quito, 13 de mayo de 2026

UNIVERSIDAD SAN FRANCISCO DE QUITO USFQ

Colegio de Ciencias e Ingenierías

HOJA DE CALIFICACIÓN DE TRABAJO DE FIN DE CARRERA

**Diseño e implementación de un índice de señales textuales de acusatoriedad
en procesos de compras públicas (GEN) mediante Procesamiento de
Lenguaje Natural**

Gian Martín Tituaña Intriago

Nombre del profesor, Título académico

Daniel Riofrío, Ph.D.

Quito, 13 de mayo de 2026

© DERECHOS DE AUTOR

Por medio del presente documento certifico que he leído todas las Políticas y Manuales de la Universidad San Francisco de Quito USFQ, incluyendo la Política de Propiedad Intelectual USFQ, y estoy de acuerdo con su contenido, por lo que los derechos de propiedad intelectual del presente trabajo quedan sujetos a lo dispuesto en esas Políticas.

Asimismo, autorizo a la USFQ para que realice la digitalización y publicación de este trabajo en el repositorio virtual, de conformidad a lo dispuesto en la Ley Orgánica de Educación Superior del Ecuador.

Nombres y apellidos: Gian Martín Tituaña Intriago

Código: 00325991

Cédula de identidad: 1751305119

Lugar y fecha: Quito, 13 de mayo de 2026

ACLARACIÓN PARA PUBLICACIÓN

Nota: El presente trabajo, en su totalidad o cualquiera de sus partes, no debe ser considerado como una publicación, incluso a pesar de estar disponible sin restricciones a través de un repositorio institucional. Esta declaración se alinea con las prácticas y recomendaciones presentadas por el Committee on Publication Ethics COPE descritas por Barbour et al. (2017) Discussion document on best practice for issues around theses publishing, disponible en <http://bit.ly/COPETheses>.

UNPUBLISHED DOCUMENT

Note: The following capstone project is available through Universidad San Francisco de Quito USFQ institutional repository. Nonetheless, this project – in whole or in part – should not be considered a publication. This statement follows the recommendations presented by the Committee on Publication Ethics COPE described by Barbour et al. (2017) Discussion document on best practice for issues around theses publishing available on <http://bit.ly/COPETheses>.

RESUMEN

La detección temprana de riesgos en la contratación pública representa un desafío técnico, especialmente cuando los indicios se encuentran en datos textuales no estructurados. En el Sistema Oficial de Contratación Pública del Ecuador (SOCE), las preguntas formuladas durante los procesos pueden contener señales relevantes de irregularidad, actualmente identificadas mediante heurísticas limitadas.

Este proyecto propone el diseño e implementación de un índice de señales textuales de acusatoriedad basado en preguntas de oferentes, empleando técnicas de Machine Learning y Procesamiento de Lenguaje Natural. La metodología se fundamenta en la replicación del protocolo experimental de Roh López (2024) mediante un ensemble de tres modelos supervisados con perfiles de error complementarios (Regresión Logística, Naive Bayes y Random Forest).

Dada la baja densidad de señales acusatorias en el régimen de Giro Específico de Negocio (GEN), el núcleo de la evaluación se traslada a los procesos de Subasta Inversa Electrónica (SIE) de 2024. En consecuencia, el régimen GEN se preserva como un escenario de validación complementario.

En este trabajo se diseña un pipeline bajo el paradigma LLM-as-a-Judge, empleando la técnica de few-shot prompting y el modelo o4-mini como árbitro semántico independiente para la generación del ground truth en los nuevos conjuntos de datos. Los resultados obtenidos confirman la viabilidad técnica y el bajo costo operativo del uso de modelos de Machine Learning; asimismo, identifican las limitaciones de la clasificación binaria a nivel de pregunta como base para construir un índice continuo a nivel de proceso, y establecen el camino metodológico hacia un indicador operativo validable.

Palabras clave: Contratación pública, procesamiento de lenguaje natural, machine learning, LLM-as-a-Judge, few-shot prompting, preguntas acusatorias, SOCE, SIE, GEN, transparencia pública.

ABSTRACT

Early detection of risks in public procurement represents a technical challenge, particularly when the relevant signals are embedded in unstructured textual data. In Ecuador's Official Public Procurement System (SOCE), the questions submitted during procurement processes may contain meaningful indications of irregularities, currently identified through limited heuristics.

This project proposes the design and implementation of a textual accusatory signals index based on bidder questions, employing Machine Learning and Natural Language Processing techniques. The methodology relies on the replication of the experimental protocol developed by Roh López (2024) through an ensemble of three supervised models with complementary error profiles (Logistic Regression, Naive Bayes, and Random Forest).

Given the low density of accusatory signals in the Giro Específico de Negocio (GEN) regime, the core of the evaluation is shifted to the Subasta Inversa Electrónica (SIE) processes of 2024. Consequently, the GEN regime is preserved as a complementary validation scenario.

In this work, a pipeline is designed under the LLM-as-a-Judge paradigm, employing the few-shot prompting technique and the o4-mini model as an independent semantic arbiter for the generation of the ground truth on the new datasets. The results obtained confirm the technical viability and the low operational cost of using Machine Learning models; they also identify the limitations of binary classification at the question level as a basis for building a continuous index at the process level, and establish the methodological pathway toward an operative and validatable indicator.

Keywords: Public procurement, natural language processing, machine learning, LLM-as-a-Judge, few-shot prompting, accusatory questions, SOCE, SIE, GEN, public transparency.

TABLA DE CONTENIDO

Introducción	12
Estado del arte.....	14
Minería de datos y aprendizaje automático en compras públicas.....	14
Procesamiento de lenguaje natural (PLN) aplicado a documentos de licitación.....	15
Análisis de redes y detección de colusión.....	15
LLM as a judge	16
Revisiones sistemáticas sobre tecnología y corrupción	17
Metodología	19
Análisis del trabajo base	20
Conjunto de datos y técnicas de data augmentation.	20
Modelos y representaciones de texto evaluado.....	20
Resultados clave y hallazgos metodológicos.....	21
Selección de modelos.....	21
Replicación del pipeline.....	23
Entrenamiento y búsqueda de hiperparámetros.	23
LLM as a judge	24
Alineamiento del prompt.	25
Generación de un ground truth.	25
Resultados y Discusión	27
Replicación del pipeline.....	27
Alineamiento del prompt	28
Evaluación SIE 2024.....	29

Dataset completo.....	29
Muestra estratificada.....	35
Evaluación GEN 2008 - 2023	39
Conclusiones	42
Trabajo Futuro	44
Nuevo enfoque metodológico	44
LLM-as-a-Judge a nivel de proceso.....	44
Implementación de IFS.....	44
Referencias bibliográficas.....	49
Anexo A: link de github.....	54

ÍNDICE DE TABLAS

Tabla 1. Algoritmos de ML elegidos para el ensemble	23
Tabla 2. Métricas de evaluación de los modelos	27
Tabla 3. Métricas por clase	28
Tabla 4. Medidas estadísticas de procesos.....	30
Tabla 5. Distribución de procesos por número de preguntas acusatorias	30
Tabla 6. Top 10 procesos por número de preguntas acusatorias	31
Tabla 7. Distribución de clasificaciones por modelo frente a la etiqueta real de la BD.....	33
Tabla 8. Concordancia por enfoque	34
Tabla 9. Comparación de las distribuciones de todas las fuentes en SIE (Modelos y Ensemble no binarizados)	37
Tabla 10. Comparación de las distribuciones de todas las fuentes en SIE (Modelos y Ensemble binarizados)	38
Tabla 11. Etiqueta BD vs Clasificación LLM	39
Tabla 12. Comparación de las distribuciones de todas las fuentes en GEN	41
Tabla 13. Ponderación de factores de contexto	45

ÍNDICE DE FIGURAS

Figura 1. Pipeline metodológico	19
Figura 2. Curvas ROC en el conjunto de test.....	27
Figura 3. Etiqueta Real vs Predicción LLM	28
Figura 4. Distribución de densidad por fuente.....	32
Figura 5. Muestreo estratificado del dataset SIE 2024	35
Figura 6. Etiqueta BD vs Clasificación LLM	35
Figura 7. Distribuciones de probabilidad de todas las fuentes en SIE (Modelos y Ensemble no binarizados)	37
Figura 8. Distribuciones de probabilidad de todas las fuentes en SIE (Modelos y Ensemble binarizados)	38
Figura 9. Etiqueta BD vs Clasificación LLM	39
Figura 10. Distribuciones de probabilidad de todas las fuentes en GEN (Modelos y Ensemble no binarizados)	40
Figura 11. Distribuciones de probabilidad de todas las fuentes en GEN (Modelos y Ensemble binarizados)	40

INTRODUCCIÓN

La contratación pública constituye uno de los mecanismos fundamentales mediante los cuales el Estado gestiona recursos y satisface necesidades colectivas. Sin embargo, debido a los altos montos involucrados y a la interacción entre múltiples actores este ámbito es particularmente vulnerable a prácticas irregulares y riesgos de corrupción. En el entorno digital actual, gran parte de la información asociada a estos procesos se encuentra disponible en plataformas electrónicas, incluyendo datos estructurados y contenido textual generado por los propios participantes.

En el Ecuador, el Sistema Oficial de Contratación Pública (SOCE) centraliza la información de los procesos contractuales, incluyendo las preguntas y respuestas publicadas durante las etapas de licitación. Actualmente, la identificación de posibles indicios de irregularidad en estos comentarios se realiza mediante revisiones manuales o heurísticas léxicas, lo que limita la escalabilidad, consistencia y capacidad preventiva del análisis. Este diagnóstico revela la necesidad de incorporar herramientas automatizadas que transformen el análisis textual en un mecanismo sistemático de priorización.

En este contexto, el presente trabajo aborda el diseño e implementación de un índice de señales textuales de acusatoriedad (IST), entendidas como aquellas intervenciones que contienen señalamientos explícitos o implícitos de posibles irregularidades en un proceso contractual. El proyecto se fundamenta en investigaciones desarrolladas en la Universidad San Francisco de Quito que han demostrado la viabilidad de aplicar Procesamiento de Lenguaje Natural (PLN) y Machine Learning para clasificar este tipo de comentarios, aunque centradas en la tarea binaria (acusatorio / no acusatorio) a nivel de pregunta.

Si bien el alcance inicial contemplaba evaluar exclusivamente los procesos del régimen de Giro Específico de Negocio (GEN), durante la implementación se evidenció que la cantidad de preguntas acusatorias disponibles en este régimen (apenas 19 de 659) resultaba insuficiente para caracterizar la distribución de estas señales a nivel de proceso. Por este motivo, la evaluación principal se trasladó al dataset de Subasta Inversa Electrónica (SIE 2024), que aporta 123669 preguntas distribuidas en 15087 procesos, mientras que GEN se preservó como caso de validación complementario. Adicionalmente, dado que la etiqueta de la base de datos no constituye un ground truth sino otra heurística léxica, se incorporó un pipeline de validación bajo el paradigma LLM-as-a-Judge, en el que un modelo de lenguaje de gran escala actúa como árbitro semántico independiente.

El trabajo se estructura de la siguiente forma: primero se revisa el estado del arte sobre detección de irregularidades en contratación pública y el uso de LLMs como evaluadores; luego se describe la metodología (replicación del pipeline fundacional, alineamiento del prompt LLM); posteriormente se exponen los resultados experimentales sobre los datasets SIE 2024 y GEN 2008–2023; finalmente se presentan las conclusiones y líneas de trabajo futuro.

En la siguiente sección se analizarán los antecedentes teóricos y técnicos que sustentan la propuesta, revisando investigaciones previas sobre detección automática de irregularidades, construcción de indicadores de riesgo en contratación pública y el uso de LLMs como evaluadores.

ESTADO DEL ARTE

Minería de datos y aprendizaje automático en compras públicas

La transparencia en los procesos de contratación pública es un área de investigación crítica donde la integración de Minería de Datos y Aprendizaje Automático (ML) ha demostrado un valor sustancial para la detección de anomalías. Diversos autores han propuesto la creación de índices y modelos de evaluación de riesgo. Fazekas et al. (2016) proponen un índice objetivo de riesgo de corrupción basado en señales de alerta (red flags) relacionadas con la competencia restringida y las adjudicaciones repetidas, validando esta métrica con proxies externos como la rentabilidad empresarial y los vínculos políticos. En la misma línea, Lisciandra et al. (2022) desarrollan un indicador aplicado a obras públicas italianas mediante un enfoque de dos etapas: la primera estima el desperdicio potencial usando Análisis Envolvente de Datos (DEA) y la segunda separa la ineficiencia estructural de la corrupción real mediante regresiones.

Para facilitar la adopción práctica de estos datos, Felizzola Jiménez et al. (2024) diseñan una herramienta de analítica visual que abarca todo un flujo (pipeline) replicable: extracción, limpieza, estandarización y visualización de datos, permitiendo así estimar indicadores de riesgo de manera operativa. Modelos más avanzados, como el implementado por Niessen et al. (2020), aplican Isolation Forest (un método de aprendizaje no supervisado) a datos del estándar OCDS en Paraguay para generar un scoring de contratos capaz de detectar anomalías y posibles fraudes. A escala global, Pastor-Sanz et al. (2024) combinan modelado de temas (topic modeling) y redes neuronales sobre más de 70000 licitaciones de 33 países, proponiendo un indicador de riesgo integral de cuatro niveles. A nivel nacional, Torres-Berru (2023) argumenta que la detección de fraude en el Sistema Oficial de Contratación Pública del Ecuador (SOCE)

requiere minería de datos y procesamiento de lenguaje a gran escala, aportando un marco metodológico clave para América Latina.

Procesamiento de lenguaje natural (PLN) aplicado a documentos de licitación

El análisis de textos no estructurados es uno de los mayores desafíos en la detección de irregularidades contractuales. Lima et al. (2023) abordan la extracción manual de red flags utilizando modelos basados en la arquitectura BERT para automatizar la identificación de señales de fraude en documentos de licitación. Posteriormente, Lima et al. (2025) presentan "BidCorpus", un conjunto de datos público de licitaciones brasileñas cuyo etiquetado combina supervisión débil y modelos BERT, alcanzando métricas de rendimiento superiores al 80%.

En el contexto específico ecuatoriano, Torres-Berru et al. (2023) aplican PLN a un corpus en español de preguntas y respuestas extraídas del SOCE, utilizando Word2Vec y VADER en un modelo híbrido capaz de detectar sesgos y favoritismos explícitos en los textos. Recientemente, Núñez (2024) evalúa el uso de Modelos de Lenguaje de Gran Escala (LLMs) como ChatGPT-4o mini y Llama 3.1 en un corpus desbalanceado de 5005 frases ecuatorianas (de las cuales solo 147 contenían características acusatorias), alcanzando un Área Bajo la Curva (AUC) de 0.972 y demostrando el altísimo potencial de los LLMs para la detección automática de acusaciones.

Análisis de redes y detección de colusión

El análisis de redes complejas (Network Science) permite modelar las relaciones comerciales entre proveedores y entidades públicas. Carbone et al. (2024) estudian la operación de carteles en subastas viales italianas, modelando indicadores a nivel de empresa y destacando que las tácticas colusorias (como la subcontratación cruzada y la similitud de precios) varían según la proporción y el tamaño de las empresas que conforman el cartel. Lei et al. (2018)

proponen un método de tres pasos que combina clustering de red y pruebas estadísticas para analizar colusión en subastas de oferta promedio.

Cuestionando la fuerte dependencia de datos tabulares tradicionales, Potin et al. (2023) proponen el enfoque PANG, basado en la identificación de subgrafos inducidos para detectar patrones anómalos en contrataciones de manera explicable. Adicionalmente, Signor et al. (2024) formulan un procedimiento operativo estadístico para construir un escenario competitivo de referencia, lo que permite detectar desviaciones y posibles colusiones en proyectos de infraestructura pública.

LLM as a judge

Más allá de las aplicaciones específicas de PLN sobre documentos de licitación, recientemente ha emergido un paradigma transversal conocido como LLM-as-a-Judge, en el cual modelos de lenguaje de gran escala son utilizados como evaluadores automáticos de textos, decisiones o salidas de otros modelos. Gu et al. (2026), en una revisión sistemática publicada en The Innovation, ofrecen la primera formalización integral de este paradigma, definiéndolo como un mecanismo de evaluación que combina la escalabilidad de las métricas automáticas con el razonamiento contextual característico del juicio experto humano. Los autores argumentan que este enfoque permite superar el dilema tradicional entre métodos subjetivos costosos (revisión por expertos) y métricas objetivas limitadas (BLEU, ROUGE), las cuales fallan en capturar matices semánticos en tareas abiertas.

Un aporte central de la revisión es la identificación de tres dimensiones críticas para evaluar la confiabilidad de un sistema LLM-as-a-Judge: la concordancia con juicios humanos, la presencia de sesgos sistemáticos (de posición, longitud, autoenaltecimiento y concreción) y la robustez frente a perturbaciones adversariales. Gu et al. (2026) además sistematizan

estrategias de mejora aplicables en tres etapas del pipeline: diseño de prompts mediante descomposición de criterios y few-shot prompting, fine-tuning especializado del modelo evaluador, y optimización post-hoc mediante integración de múltiples evaluaciones o autovalidación. Sus experimentos empíricos muestran que estrategias simples como el votado por mayoría en evaluaciones repetidas y la rotación de posiciones en comparaciones pareadas mitigan eficazmente varios sesgos sin requerir reentrenamiento.

Esta literatura es directamente relevante para el presente trabajo, ya que fundamenta el uso de un LLM externo como árbitro semántico independiente para construir un ground truth alternativo frente a la heurística léxica de la base de datos del SOCE, evitando la dependencia circular que surgiría al validar los modelos del ensemble contra etiquetas generadas por el mismo corpus de entrenamiento.

Revisiones sistemáticas sobre tecnología y corrupción

Múltiples estudios de revisión consolidan la madurez de este campo. Luna et al. (2020) enfatizan que las estrategias manuales son insuficientes para la auditoría moderna y que el uso de IA y big data es prometedor, aunque hacen falta modelos automáticos específicos según el tipo de delito. Nai et al. (2022) sintetizan el uso de ML y NLP, destacando los desafíos relacionados con la calidad de los datos y las dificultades de despliegue en entornos gubernamentales reales.

Sanchez-Chero et al. (2025) analizan impactos y retos regulatorios, resaltando la corrupción estructural imperante en América Latina, mientras que reportan notables mejoras en eficiencia en administraciones donde la IA se aplica exitosamente. Lyra et al. (2022) señalan que el clustering y las medidas de centralidad dominan el análisis de redes de proveedores, pero alertan sobre la escasez de estudios empíricos robustos a nivel microeconómico.

Modrusan et al. (2021) identifican las reglas de asociación y las bases de datos de grafos como tecnologías emergentes clave para descubrir colusión oculta. Por su parte, Gnaldi y Del Sarto (2024) proponen esquemas adaptables con red flags curadas específicamente para medir el riesgo de corrupción en contextos de crisis o emergencia.

METODOLOGÍA




Figura 1. Pipeline metodológico

Análisis del trabajo base

El trabajo de Francisco Roh (2024) constituye la base técnica y metodológica directa de la presente investigación. Su estudio se enfoca en resolver el problema de la detección de comentarios acusatorios con indicios de corrupción en los procesos de compras públicas de Ecuador, extrayendo información del SOCE.

Conjunto de datos y técnicas de data augmentation.

El experimento partió de un conjunto de datos base que constaba de 5005 registros etiquetados manualmente de forma binaria. El desafío principal radicaba en que el dataset presentaba un desbalance extremo: un 97% de las muestras no contenía indicios de corrupción, frente a solo un 3% de ejemplos con comentarios acusatorios. Para mitigar este problema de clases desbalanceadas, Roh aplicó múltiples técnicas de aumento de datos (Data Augmentation) destinadas a incrementar la diversidad del corpus de entrenamiento. Las técnicas empleadas incluyeron el uso de reemplazo por sinónimos a través de WordNet , la inserción y sustitución inteligente de palabras utilizando el transformer BERT , y la generación de texto parafraseado y contextualizado mediante llamadas a la API de los modelos de lenguaje GPT-2 y GPT-4o mini. En total, estas técnicas generaron 36 conjuntos de datos de prueba con distintas características de balanceo y tamaño.

Modelos y representaciones de texto evaluado.

La investigación fue exhaustiva en la comparación de arquitecturas, evaluando modelos de aprendizaje automático tradicionales (Regresión Logística, Naive Bayes, Random Forest Classifier y Máquinas de Vectores de Soporte o SVC). Estos clasificadores fueron combinados con métodos convencionales de representación de texto como Bag of Words (BoW) y TF-IDF , y posteriormente escalados usando embeddings entrenados y pre-entrenados como Doc2Vec,

FastText, SBERT y text-embedding-3-large. Paralelamente, se implementaron modelos de aprendizaje profundo basados en Redes Neuronales Recurrentes (LSTM y GRU bidireccionales) y potentes Transformers de lenguaje natural (BERT y RoBERTa).

Resultados clave y hallazgos metodológicos.

Los resultados demostraron empíricamente que las técnicas de aumento de datos son fundamentales e irremplazables para mejorar el rendimiento de los modelos al lidiar con clases minoritarias en textos. Además, las representaciones semánticas avanzadas, en particular SBERT y text-embedding-3-large, permitieron que los algoritmos detectaran patrones lingüísticos complejos que escapaban a modelos de frecuencia, logrando puntuaciones AUC-ROC significativamente superiores y más estables frente a las representaciones tradicionales.

Los modelos basados en Transformers (BERT y RoBERTa) mostraron el desempeño general superior en métricas críticas como el F1-Score y el Recall. Tener un alto Recall es ideal para sistemas de alerta temprana, pues minimiza los falsos negativos al evitar que las acusaciones de corrupción pasen desapercibidas. La limitante principal de estos Transformers fue la alta exigencia computacional (runtime) requerida para su inferencia. Roh encontró que dejar todas las capas entrenables (unfrozen) en estos Transformers produjo mejores resultados, puesto que congelar las capas degradó severamente el F1-Score final.

Selección de modelos.

Se propone el uso de tres clasificadores con perfiles de error complementario. Esto se fundamenta en el principio de diversidad de clasificadores establecido por Kuncheva y Whitaker (2003) quienes demostraron mediante 10 estadísticos de diversidad que los clasificadores que deben combinarse en un ensemble no son los más precisos individualmente, sino los más diversos en sus patrones de error. Tumer y Ghosh (1996) demostraron

matemáticamente que combinar clasificadores con errores no correlacionados reduce el error del ensemble de forma proporcional al número de modelos.

El uso de ensembles con perfiles complementarios tiene precedentes directos en sistemas operativos de vigilancia de contratación pública. Salazar, Pérez y Gallego (2024), a través de VigIA, un sistema, desarrollado para la Veeduría Distrital de Bogotá con apoyo de CAF, integra múltiples modelos de ML para detectar ineficiencias y construye índices de riesgo para transparencia y competencia sobre 87387 contratos del SECOP II colombiano. Gallego, Rivero y Martínez (2021) entrenaron modelos de alerta temprana sobre más de 2 millones de contratos colombianos, estableciendo el paradigma de prevención frente a sanción en contratación pública latinoamericana.

A escala continental, ARACHNE de la Comisión Europea calcula 106 indicadores de riesgo clasificados en 7 categorías, asigna puntajes individuales (0-40 por indicador) y produce un score general por categoría. Ha evaluado más de 1.2 millones de proyectos con valor de 330 mil millones de euros en fondos de la UE. Sin embargo, la herramienta recibió la calificación de efectividad percibida más baja en estudios del EPRC, debido principalmente a su alta tasa de falsos positivos.

En el contexto del índice de señales textuales de acusatoriedad, los tres modelos seleccionados del catálogo experimental de Roh López (2024) exhiben precisamente esta propiedad de diversidad complementaria. M1 (Regresión Logística) opera como decisor central optimizando el F1-Score, M2 (Naive Bayes) actúa como red de seguridad maximizando el Recall y M3 (Random Forest) funciona como árbitro maximizando la Precisión. Todos los modelos poseen un $AUC-ROC \geq 0.940$ para garantizar la capacidad discriminativa del modelo a diferentes umbrales.

Modelo	Algoritmo	Perfil de error	Umbral (τ)	Funcionalidad
M1	Logistic Regression	Equilibrado	0.50	Decisor central (Máximo F1)
M2	Naive Bayes	Sensible	0.50	Red de seguridad (Recall = 1.0)
M3	Random Forest	Conservador	0.50	Árbitro (Máxima Precisión)

Tabla 1. Algoritmos de ML elegidos para el ensemble

Replicación del pipeline.

Como comprobación de los resultados expuestos en el trabajo fundacional, se replicó el pipeline de detección de preguntas acusatorias propuesto por Roh López (2024) enfocada en tres modelos seleccionados del esquema final: un modelo equilibrado (Regresión Logística), un modelo sensible (Naive Bayes) y un modelo conservador (Random Forest).

El objetivo de esto fue obtener los binarios de los modelos para poder ser probados en nuevos datasets. Aunque el notebook conserva el código de preprocesamiento, aumentación y generación de embeddings, la ejecución principal de la réplica se apoya en embeddings precomputados. Esto reduce costo y tiempo de cómputo, y minimiza variaciones por llamadas externas, manteniendo la coherencia con el experimento original.

Entrenamiento y búsqueda de hiperparámetros.

La optimización se realiza con: GridSearchCV, StratifiedKFold de 3 particiones, con mezcla y semilla fija, métrica objetivo de selección: F1, paralelización con `n_jobs=8`.

Espacios de búsqueda:

- Regresión Logística: C, tipo de penalización y solver.
- Naive Bayes: var_smoothing en escala logarítmica.
- Random Forest: número de árboles, profundidad máxima y mínimo de muestras por hoja.

LLM as a judge

Una limitación recurrente en el análisis de las secciones anteriores es que la etiqueta binaria de la base de datos oficial no constituye un ground truth genuino, sino otra heurística basada en búsqueda léxica. Comparar los modelos individuales, el ensemble o el índice de señales textuales de acusatoriedad contra esta etiqueta mide acuerdo entre dos sistemas imperfectos, no desempeño absoluto. Para superar esta limitación se diseñó un pipeline complementario basado en el paradigma LLM-as-a-Judge (Zheng et al., 2023) que utiliza un modelo de lenguaje de gran escala como árbitro semántico independiente del corpus de entrenamiento original.

Los modelos M1, M2 y M3 se entrenan sobre el corpus etiquetado manualmente de 5005 preguntas que utiliza Roh López (2024). Comparar sus predicciones contra etiquetas generadas por otro modelo entrenado sobre ese mismo corpus introduce dependencia circular. Un LLM general como OpenAI o4-mini, en cambio, no fue afinado sobre estas preguntas y aplica capacidad de razonamiento lingüístico genérico, lo que lo convierte en un evaluador externo cuyo error es presumiblemente independiente del error de los modelos del ensemble. Núñez (2024) reportó que LLMs alcanzan AUC de 0.972 sobre el mismo corpus base de 5005 frases ecuatorianas, evidencia previa que respalda la viabilidad técnica del enfoque para esta tarea específica.

Alineamiento del prompt.

La primera etapa es la partición estratificada del dataset global (80/20) que produce un conjunto de entrenamiento de 4004 preguntas y un test de 1001 preguntas, dentro del 80% se hace una segunda partición (75/25) que produce train_inner (3003 preguntas) y val_inner (1001 preguntas).

La segunda etapa es el diseño del prompt base con few-shot prompting. El prompt_v1 contiene una definición operativa de pregunta acusatoria centrada en el criterio de imputación de dolo o mala fe a la entidad contratante. El prompt incluye ocho ejemplos few-shot (cuatro acusatorios, cuatro no acusatorios) muestreados aleatoriamente de train_inner. La salida del modelo se restringe a una de dos cadenas exactas: ACUSATORIA o NO_ACUSATORIA.

La tercera etapa es el refinamiento iterativo automático, donde un meta-prompt analiza los falsos negativos y falsos positivos producidos sobre val_inner y solicita al propio LLM una revisión del prompt original. El loop se detiene cuando $F1 \geq 0.90$, cuando hay tres iteraciones consecutivas sin mejora, o cuando se alcanzan quince iteraciones. La última etapa es la validación del prompt seleccionado sobre test completo (101 preguntas) antes de su uso en la muestra operativa.

Generación de un ground truth.

El prompt validado se utiliza para construir el ground truth de referencia sobre una muestra estratificada de 471 procesos del dataset SIE 2024 y para del dataset completo de 111 procesos del dataset GEN 2008-2023. El motivo para evaluar en ambos datasets es por el hecho que los procesos de GEN cuenta con 659 preguntas de las cuales solo 19 son acusatorias lo cual imposibilita analizar detalladamente la distribución de este tipo de preguntas a lo largo de los procesos.

Ahora bien, para cada pregunta de los procesos seleccionados, el LLM aplica el prompt con few-shot prompting y produce una etiqueta binaria que se considera la referencia para esa muestra. A partir de estas etiquetas se construye la densidad acusatoria por proceso (preguntas acusatorias sobre el total de preguntas del proceso) bajo cinco fuentes: (1) BD oficial, (2) modelo M1 individual, (3) modelo M2 individual, (4) modelo M3 individual, (5) ensemble por media simple, y (6) LLM-as-a-Judge. La comparación de las primeras cinco contra la sexta permite realizar un análisis de distribuciones (KDE) y gráficos de utilidad operativa, respondiendo formalmente la pregunta de cuál enfoque muestra el mejor rendimiento.

RESULTADOS Y DISCUSIÓN

Replicación del pipeline

En general los resultados verificaron la reproducibilidad del experimento, y fundamentaron las bases para el desarrollo de la propuesta metodológica. A continuación, un resumen de los resultados:

Modelo	ROC_area	Test_Recall	Test_Precision	Test_F1	TP	FN	FP	TN
M1 — LR (ref.)	0.940	0.759	0.611	0.677	22	7	14	958
M2 — NB (ref.)	0.940	1.000	0.128	0.227	29	0	198	774
M3 — RFC (ref.)	0.940	0.552	0.762	0.640	16	13	5	967
M1 — LR (rep.)	0.942	0.759	0.611	0.677	22	7	14	958
M2 — NB (rep.)	0.941	0.966	0.124	0.220	28	1	198	774
M3 — RFC (rep.)	0.934	0.483	0.737	0.583	14	15	5	967

Tabla 2. Métricas de evaluación de los modelos




Figura 2. Curvas ROC en el conjunto de test

Los resultados fueron muy similares a los de la referencia lo cual permitió utilizar estos modelos para la evaluación en nuevos datasets.

Alineamiento del prompt

Para el alineamiento del prompt se utilizó el modelo de OpenAI o4-mini con un reasoning effort = medium, para evaluar el prompt en cada una de las 17 iteraciones realizadas. Una vez se alcanzó un desempeño aceptable dentro del conjunto de validación se evaluó en el conjunto de test global y se obtuvieron los siguientes resultados:




Figura 3. Etiqueta Real vs Predicción LLM

Clase	Precisión	Recall	F1-score
Clase no acusatoria	0.99	0.99	0.99
Clase acusatoria	0.70	0.72	0.71

Tabla 3. Métricas por clase

Se obtuvo un MCC (Matthews correlation coefficient): 0.7032 que implica que el modelo aprendió patrones significativos que distinguen el comportamiento honesto de la posible conducta acusatoria. Además, existe una alta tasa de verdaderos positivos y verdaderos

negativos, mientras que los errores (falsos positivos y falsos negativos) se mantienen en un nivel bajo y controlado.

Evaluación SIE 2024

Dataset completo.

Este dataset contiene 123669 preguntas de 15087 procesos con una prevalencia acusatoria del 4.78%. A continuación se muestran estadísticas de los procesos existentes en la base de datos.

Métrica	Valor
Procesos con preguntas	15087
Total preguntas acusatorias	5914
Media (por proceso)	0.39
Mediana	0.00
Desviación estándar	1.17
Mínimo	0
Máximo	39
Percentil 10	0.00
Percentil 25	0.00
Percentil 75	0.00

Métrica	Valor
Percentil 90	1.00
Percentil 95	2.00

Tabla 4. Medidas estadísticas de procesos

La distribución es extremadamente asimétrica a la derecha: la mediana es 0 y el 75 percentil también es 0, lo que indica que la mayoría de los procesos no registra ninguna pregunta acusatoria.

Rango de preguntas acusatorias	N.º de procesos	Participación (%)
0	11882	78.76 %
1–2	2633	17.45 %
3–5	452	3.00 %
6–10	94	0.62 %
11–20	21	0.14 %
21–40	5	0.03 %
> 40	0	0.00 %

Tabla 5. Distribución de procesos por número de preguntas acusatorias

El 78.8 % de los procesos no contiene ninguna pregunta acusatoria. Solo 26 procesos (0.17 %) superan las 10 preguntas acusatorias; estos constituyen el subconjunto "denso".

Proceso	Fecha	Preg. acusatorias	Total preguntas
1854824	2024-04-29	39	76
1916846	2024-12-09	23	115
1852179	2024-04-25	22	39
1858726	2024-05-14	21	66
1895647	2024-10-03	21	88
1846269	2024-03-25	20	67
1902006	2024-10-25	20	249
1888944	2024-09-09	19	140
1891022	2024-09-17	17	42
1870038	2024-06-27	15	64

Tabla 6. Top 10 procesos por número de preguntas acusatorias

Clasificación binaria de los modelos.




Figura 4. Distribución de densidad por fuente

Para la clasificación se generó el embedding completo con text-embedding-3-large (\$0.13 x 1M tokens, costo aproximado = \$2-3 USD) y se definió al umbral de clasificación de 0.5 para todos los modelos.

Una vez evaluados cada uno de los procesos se observó que las distribuciones los M1, M3 y ensemble para los procesos con señal acusatoria de la base de datos se concentran alrededor del cero, mientras de M2 y la base de datos están clasificando como acusatorias muchas preguntas que los otros modelos no están considerando como riesgosas.

Distribución de clasificaciones a nivel de pregunta.

A continuación se sintetiza la distribución de clasificaciones producidas por cada modelo frente a la etiqueta real de la base de datos, sobre el universo completo de 123669 preguntas.

Fuente	N.º acusatorias	% del total	Procesos con señal
BD (etiqueta real)	5914	4.78%	3205 (21.24%)
M1 — LR	3659	2.96%	1977 (13.10%)
M2 — NB	25884	20.93%	8286 (54.92%)
M3 — RFC	1548	1.25%	937 (6.21%)
Ensemble	3940	3.19%	2128 (14.10%)

Tabla 7. Distribución de clasificaciones por modelo frente a la etiqueta real de la BD

Los datos evidencian un patrón de comportamiento marcadamente diferenciado entre los tres clasificadores. M2 (Naive Bayes) produce el mayor volumen de positivos con 25884 predicciones acusatorias (20.93%), superando en más de cuatro veces la prevalencia real de la clase (4.78%). En el extremo opuesto, M3 (Random Forest) clasifica apenas 1548 preguntas como acusatorias (1.25%), representando menos de la mitad de los casos reales confirmados. M1 y el ensemble ocupan una posición intermedia, con 3659 y 3940 predicciones positivas respectivamente, ambas por debajo de la prevalencia real.

Análisis de concordancia con la base de datos.

A continuación se presenta el análisis de concordancia entre cada modelo y la etiqueta de la BD. La columna A registra el número de preguntas donde el modelo y la BD coinciden en clasificar como acusatoria; B corresponde a casos acusatorios en la BD no detectados por el modelo; C a casos clasificados como acusatorios por el modelo pero no confirmados por la BD. Para todos los enfoques se utilizó el umbral de 0.5.

Modelo	A (Acuerdo)	B (Solo BD)	C (Solo ML)	Concordancia
M1 (LR)	1448	4466	2211	0.9460
M2 (NB)	4018	1896	21866	0.8079
M3 (RFC)	711	5203	837	0.9512
Ensemble	1525	4389	2415	0.9450

Tabla 8. Concordancia por enfoque

El análisis de concordancia revela una tensión estructural que atraviesa todos los modelos evaluados. M2 presenta la cobertura más alta recuperando dos tercios de las preguntas acusatorias reales, pero al costo de producir 21866 falsos positivos prácticamente cuatro veces el número total de casos reales. Esta proporción haría inviable su uso operativo de forma independiente, dado que sobrecargaría los recursos de auditoría. M3, por su parte, maximiza la concordancia global (0.9512) y minimiza los falsos positivos, pero a expensas de dejar sin detectar el 87.98% de los casos reales confirmados. El ensemble, cuya concordancia (0.9450-0.9464) es apenas ligeramente inferior a la de M3, captura únicamente entre el 24% y el 26% de los casos etiquetados por la BD, lo que subraya los límites de la cobertura del sistema en su configuración actual.

Muestra estratificada.

Con el rendimiento del prompt validado, se decidió utilizarlo en una muestra estratificada de SIE 2024 para generar un ground truth a nivel de pregunta contra el cual comparar el rendimiento de los distintos enfoques. Para lograr que la muestra sea representativa se realizó un muestreo estratificado de 471 procesos.




Figura 5. Muestreo estratificado del dataset SIE 2024

El costo computacional aproximado de la clasificación utilizando o4-mini (reasoning_effort=low) fue de \$8.39.




Figura 6. Etiqueta BD vs Clasificación LLM

Cálculo del índice de riesgo por proceso.

Para cada proceso p con n_p preguntas, el IST (Índice de Señales Textuales de Acusatoriedad) por media simple se define como:

$$IST_p^{(m)} = 100 \times \frac{1}{n_p} \sum_{i=1}^{n_p} P_m(c_i)$$

donde $P_m(c_i)$ es la probabilidad asignada por el modelo m a la pregunta i . Para el ensemble se utiliza la probabilidad promedio por pregunta antes de agregar al proceso: $P_{ens}(c_i) = (P_{M1}(c_i) + P_{M2}(c_i) + P_{M3}(c_i))/3$.

Adicionalmente se construyó una representación binarizada de cada estimador, en la que cada pregunta se convierte a 0/1 aplicando un umbral uniforme de 0.50 y se calcula la proporción de preguntas acusatorias por proceso. Esta representación permite una comparación en la misma escala conceptual que BD y LLM Judge, ya que ambas referencias son proporciones de etiquetas binarias mientras que el IST es una media de probabilidades continuas. Para comparar las distribuciones del IST por proceso se emplearon dos métricas respecto al LLM Judge: distancia de Wasserstein y KL divergencia. Ambas familias de métricas sobre (IST continuo y sobre proporciones binarizadas) se calcularon de forma separada para examinar si el ranking de similitud cambia según la representación empleada.




Figura 7. Distribuciones de probabilidad de todas las fuentes en SIE (Modelos y Ensemble no binarizados)

Fuente	Wasserstein (pp)	KL discreta	Rank W	Rank KL
M1 — Equilibrado (LR)	1004	0.0287	1	1
BD (etiqueta histórica)	1.446	0.0527	2	2
M3 — Conservador (RFC)	9.337	1.3305	3	5
Ensemble (media simple)	9.395	0.4760	4	3
M2 — Sensible (NB)	17.941	0.7791	5	4

Tabla 9. Comparación de las distribuciones de todas las fuentes en SIE (Modelos y Ensemble no binarizados)




Figura 8. Distribuciones de probabilidad de todas las fuentes en SIE (Modelos y Ensemble binarizados)

Fuente	Wasserstein (pp)	KL discreta	Rank W	Rank KL
M1 — Equilibrado (LR)	0.598	0.0262	1	1
BD (etiqueta histórica)	1.446	0.0527	2	2
M3 — Conservador (RFC)	1.544	0.1090	3	4
Ensemble (media simple)	1.998	0.0689	4	3
M2 — Sensible (NB)	17.856	0.7778	5	5

Tabla 10. Comparación de las distribuciones de todas las fuentes en SIE (Modelos y Ensemble binarizados)

M1 lidera en ambas representaciones y por todas las métricas. La comparación entre las dos tablas revela un efecto de escala importante: en la versión continua, M3 y el Ensemble se distancian fuertemente del LLM Judge, mientras que en la binarizada la distancia cae a 1,5 y 2,0 pp respectivamente.

Este colapso se explica porque el IST continuo de M3 está sistemáticamente mientras que al binarizar con umbral 0.50 se filtra esa inflación y la proporción de positivos por proceso

converge con la del LLM. En otras palabras, M3 produce probabilidades altas en preguntas que finalmente no clasifica como acusatorias; el IST captura esa incertidumbre pero la binarización la suprime.

Evaluación GEN 2008 - 2023

Para la clasificación binaria de los modelos se generó el embedding completo con text-embedding-3-large (\$0.13 x 1M tokens) y se definió al umbral de clasificación de 0.5 para todos los modelos.

Para generar el ground truth se clasificaron 659 preguntas de 111 procesos donde la prevalencia acusatoria de acuerdo a la base de datos era de 2.88%. La clasificación binaria se realizó con o4-mini (reasoning_effort=medium) a partir del prompt alineado.




Figura 9. Etiqueta BD vs Clasificación LLM

Se observan 19 falsos positivos que resultan del stemming del método de la base de datos que captura coincidencias de palabras como dirección, límite, trato justo sin tener un general de la pregunta. Además, se observan 2 falsos negativos que la base de datos no pudo obtener y que presentan claras señales textuales acusatorias. Algunos fragmentos: “PREGUNTO POR QUE SETRANSGREDEN LOS PRINCIPIOS DE TRANSPARENCIA POR QUE SE DISCRIMINA A LAS PERSONAS NATURALES DESDE LA CONVOCATORIA”, “SOLICITE SE ACLARE PORQUE SE EXCLUYE DE LA PARTICIPACION A LAS PERSONAS NATURALES O ES QUE ACASO YA ESTAN CONDEDICATORIA LOS PLIEGOS?????”




Figura 10. Distribuciones de probabilidad de todas las fuentes en GEN (Modelos y Ensemble no binarizados)




Figura 11. Distribuciones de probabilidad de todas las fuentes en GEN (Modelos y Ensemble binarizados)

Fuente	Wasserstein	Divergencia KL
M3 binarizado	0.9745	12.9071
M1 binarizado	1.7367	13.2062
Ensemble binarizado	1.7367	13.2062
M1	2.3676	13.3438
BD	3.2133	13.8930
M3	11.5240	17.2010
Ensemble	13.7281	16.2221
M2	27.2927	16.7756
M2 binarizado	27.5791	16.7862

Tabla 12. Comparación de las distribuciones de todas las fuentes en GEN

El problema de visualización se debe a que el LLM Judge tiene casi todos los valores en 0 (solo 2 preguntas acusatorias en 111 procesos), lo que genera un pico KDE enorme (~ 1.7) cerca del 0 que aplasta el resto de curvas. Eso eleva los KL de todas las fuentes, así que lo relevante es el orden relativo, no el valor absoluto.

M1/M3/Ensemble binarizados quedan más cerca del LLM Judge que sus versiones continuas. Al binarizar se elimina la "masa" de probabilidades intermedias que el LLM Judge no produce. M2 es el outlier: tanto en continuo como en binarizado tiene las distancias más altas. Su tendencia a asignar probabilidades altas lo aleja estructuralmente del LLM Judge.

BD no es la más cercana: Wasserstein = 3.21 sitúa a BD por detrás de los tres modelos binarizados, lo que indica que el LLM Judge es sistemáticamente más estricto que el etiquetado humano de la BD.

CONCLUSIONES

El proyecto estableció una línea base metodológica para la detección de señales textuales de acusatoriedad, mediante el diseño y evaluación de una propuesta basada en modelos de Machine Learning que servirá como puente entre los flujos experimentales de la literatura y un futuro índice operativo. Las contribuciones específicas se resumen en los siguientes puntos:

- **Replicación reproducible del pipeline fundacional:** Se reprodujeron de forma exitosa los tres clasificadores M1 (Regresión Logística), M2 (Naive Bayes) y M3 (Random Forest) entrenados sobre el corpus de 5005 preguntas de Roh López (2024).
- **Desempeño de la propuesta.** El desempeño absoluto de la propuesta construida no puede cuantificarse en ausencia de un ground truth válido a nivel de proceso, pero permite realizar un diagnóstico sobre los límites del enfoque y abre nuevas posibilidades para investigación posterior.
- **Convergencia a nivel de densidad:** La línea base del índice por media de probabilidades reproduce la distribución del porcentaje de preguntas acusatorias según la evaluación del LLM lo cual a nivel macro da una idea de que está haciendo un trabajo similar.
- **Escalabilidad:** El sistema entrega una priorización reproducible a costos computacionales y económicos bajos (generación de embeddings).
- **Preguntas acusatorias como proxy:** La clasificación binaria a nivel de pregunta no es base suficiente para construir un índice de riesgo continuo a nivel de proceso. La identidad de quien pregunta, la repetición de cuestionamientos por un mismo oferente, el historial del proceso y las características de la entidad contratante no entran en la decisión y, por lo tanto, no entran en el indicador.

- **Limitaciones del LLM as a Judge:** El LLM es empleado como un clasificador binario alineado al mismo criterio del corpus de entrenamiento, y no produce un ground truth a nivel de proceso. Su alineamiento con el criterio humano original es deseable a nivel de pregunta pero no a nivel de proceso.
- **Ausencia de una referencia externa:** No existe una referencia externa contra la cual contrastar el ranking: la BD es una heurística léxica, el LLM es un clasificador binario alineado al mismo criterio del corpus de entrenamiento, y ninguno produce un ground truth a nivel de proceso.

TRABAJO FUTURO

Nuevo enfoque metodológico

El éxito de un futuro índice operativo solo será posible si se le comparar con un ground truth válido que etiquetar a nivel de proceso, no de pregunta, mediante revisión por auditores expertos sobre una muestra, que además, incorpore información sobre el contexto del proceso, por ejemplo la identidad del oferente, entidad, monto, objeto, historial de la entidad, características del pliego y tome en cuenta las que las preguntas formuladas por un mismo oferente o que repitan literalmente cuestionamientos previos pueden inflar el riesgo. Las siguientes propuestas podrían ser un buen punto de partida.

LLM-as-a-Judge a nivel de proceso.

Proveerle a un LLM la información asociada al proceso, es decir, todo el set de preguntas acusatorias y no acusatorias, la información contextual del proceso como el monto adjudicado, la identidad del oferente, etc., y pedirle un score asociado entre 0 y 1 de cuán riesgoso considera al proceso.

Implementación de IFS.

Implementación de la propuesta del IFS (Intensidad x Frecuencia x Severidad) basado en el RPN (Risk Priority Number)

Plan de modelado del indicador.

El núcleo de la propuesta tecnológica se divide en dos fases operativas: la detección en tiempo real mediante un *ensemble* multimodelo y la generación de un índice continuo de riesgo a nivel de proceso.

Se plantea el uso de ensembles con perfiles complementarios ya que esto tiene precedentes directos en sistemas operativos de vigilancia de contratación pública. Dadas las características de cada modelo se propone el uso de umbrales asimétricos diferenciados por modelo ($\tau_1=0.50$, $\tau_2=0.30$, $\tau_3=0.65$) se fundamentan en la literatura de *cost-sensitive learning* para contextos donde los costos de error son asimétricos.

En auditoría gubernamental, un falso negativo (caso de corrupción no detectado) puede implicar pérdidas millonarias de recursos públicos, mientras que un falso positivo (revisión innecesaria) tiene un costo marginal comparativamente menor. Höppner, Baesens, Verbeke y Verdonck (2022) proponen umbrales dependientes de la instancia basados en matrices de costo específicas por transacción.

Descomposición dimensional del IFS.

Nivel 1: probabilidad ajustada por contexto.

Para cada comentario c_i , se ajusta la probabilidad del modelo base (M1) mediante factores externos al texto:

$$Score(c_i) = \min(P_{ML}(c_i) \times Factor_contexto(c_i), 1.0)$$

El *Factor_contexto* se define como:

$$0.4 \times F_{etapa} + 0.3 \times F_{longitud} + 0.3 \times F_{técnico}$$

Subfactor	Condición de aplicación	Valor
F_{etapa}	Pregunta de proveedor (vs. aclaración entidad)	1.3
$F_{longitud}$	Comentarios extensos (> No. caracteres)	1.2
$F_{técnico}$	Alta densidad de términos (especificaciones, pliegos, etc.)	hasta 1.5

Tabla 13. Ponderación de factores de contexto

Ajuste contextual.

La probabilidad cruda $P_ML(c_i)$ que produce el modelo mide exclusivamente la similitud lingüística de una pregunta con el corpus etiquetado de entrenamiento. Sin embargo, una pregunta acusatoria existe dentro de un proceso contractual con características estructurales que modifican su significado operativo. Katona y Fazekas (2024) demostraron con 119000 contratos húngaros (2011-2020) que la inclusión de datos textuales junto con variables estructuradas mejoró la precisión del modelo de 77% a 82%, validando que el texto por sí solo pierde información que el contexto estructural recupera. Este hallazgo fundamenta la necesidad de algún mecanismo que reinyecte al score la información contextual que el modelo NLP no pudo ver. Para este proyecto se propone lo siguiente: A diferencia de modelos de lenguaje genéricos, el dataset Kapak integra variables del dominio de la contratación pública para ajustar la probabilidad bruta : (P_{ML})

- **Etapas del proceso:** Se pondera con un factor de 1.3 a las preguntas de proveedores, dada su mayor carga histórica de irregularidades.
- **Densidad técnica:** Se aplica un factor $F_{técnico}$ (hasta 1.5) basado en la presencia de términos jurídico-administrativos como "pliegos", "resolución" o "especificaciones".

Nivel 2: Agregación a nivel de proceso (fórmula IFS).

El riesgo del proceso $p(IST4_p)$ se calcula mediante la combinación de tres dimensiones:

Intensidad ($\bar{I}_p$), Frecuencia (F_p) y Severidad (S_p):

$$IST4_p = 100 \times (w_1 \bar{I}_p + w_2 F_p + w_3 S_p)$$

Donde los pesos iniciales propuestos para el piloto son $w_1 = 0,45$, $w_2 = 0,35$ y $w_3 = 0,20$.

- Intensidad ($\bar{I}_p$): Promedio simple de los scores ajustados del proceso.

- Frecuencia (F_p): Proporción de comentarios con $Score(c_i) \geq 0,60$.
- Severidad (S_p): Máximo peso detectado según la taxonomía de irregularidades (e.g., Direccionamiento = 0,9; Sobreprecio = 0,6).

La fórmula $IST_p = 100 \times (w_1 \cdot \bar{I}_p + w_2 \cdot F_p + w_3 \cdot S_p)$ no es una construcción ad hoc: replica la arquitectura lógica de dos tradiciones metodológicas convergentes que han demostrado eficacia empírica en dominios análogos.

La primera tradición es el Risk Priority Number (RPN) del análisis FMEA (Failure Mode and Effects Analysis), desarrollado originalmente por la NASA en los años 1960 y estandarizado por la industria automotriz (AIAG/VDA FMEA Handbook, 2019). El RPN descompone el riesgo en tres dimensiones: Severidad $\times$ Ocurrencia $\times$ Detección. Cada factor se califica en escala 1-10, produciendo un rango de 1-1,000 que permite priorizar modos de falla. La analogía con el índice es estructuralmente precisa: Severidad del tipo de irregularidad, Ocurrencia mapeada a Frecuencia de señales acusatorias, y Detección invertida como complemento de Intensidad (a mayor probabilidad del modelo, más clara la señal).

Elección de pesos iniciales ($w_1=0.45$, $w_2=0.35$, $w_3=0.20$).

Los pesos propuestos son pesos iniciales para el piloto, no valores definitivos. Esta decisión se alinea con la recomendación del Handbook on Constructing Composite Indicators (Nardo, Saisana, Saltelli et al., 2008) de iniciar con pesos basados en juicio informado y refinarlos mediante análisis de sensibilidad iterativo. El Handbook cataloga ocho métodos de ponderación y enfatiza que ningún escenario de ponderación es a priori superior, siempre que se garantice coherencia interna y se realice un análisis de robustez.

La asignación inicial $w_1 > w_2 > w_3$ se justifica por las siguientes razones:

- **Intensidad recibe el mayor peso (0.45)** porque constituye la señal primaria del sistema: la probabilidad calibrada del modelo NLP es el único insumo que distingue este enfoque del baseline heurístico de la BD. Si la Intensidad no domina el índice, el IST no ofrecería valor agregado sobre el full-text search existente.

- **Frecuencia recibe peso intermedio (0.35)** porque la proporción de preguntas acusatorias en un proceso captura la sistematicidad del cuestionamiento, que es informativamente distinta de la confianza individual del modelo. Un proceso con muchas señales moderadas puede ser más preocupante que uno con una señal fuerte aislada.

- **Severidad recibe el menor peso (0.20)** porque en el prototipo actual la asignación de severidad depende de una taxonomía de irregularidades que aún no ha sido validada empíricamente contra resultados de auditoría. Asignar un peso menor a la dimensión menos validada es una decisión de prudencia metodológica coherente con las recomendaciones de Becker, Paruolo, Saisana y Saltelli (2017), quienes demostraron que los pesos asignados no se traducen directamente en importancia de las variables.

REFERENCIAS BIBLIOGRÁFICAS

- Becker, W., Paruolo, P., Saisana, M., & Saltelli, A. (2017). Weights and importance in composite indicators: Closing the gap. *Ecological Indicators*, 80, 12-22.
- Carbone, C., Calderoni, F., & Jofre, M. (2024). Bid-rigging in public procurement: cartel strategies and bidding patterns. *Crime, Law and Social Change*, 82, 249-281.
- Decarolis, F., & Giorgiantonio, C. (2022). Corruption red flags in public procurement: new evidence from Italian calls for tenders. *European Journal of Political Economy*, 102241.
- Del Sarto, S., Gnaldi, M., & Salvini, N. (2024). Sustainability and high-level corruption in healthcare procurement: Profiles of Italian contracting authorities. *Socio-Economic Planning Sciences*, 95, 101988.
- Fazekas, M., Cingolani, L., & Tóth, B. (2016). *A comprehensive review of objective corruption proxies in public procurement: risky actors, transactions, and vehicles of rent extraction*. GTI-WP/2016:3.
- Felizzola Jiménez, H., Gomez, C., Arrieta, N., Jerez, V., Erazo, Y., & Camacho, G. (2024). Enhancing transparency in public procurement: A data-driven analytics approach. *Information Systems*, 125, 102430.
- Frachot, A., Georges, P., & Roncalli, T. (2001). *Loss Distribution Approach for Operational Risk*. SSRN:1032523.
- Gallego, J., Rivero, G., & Martínez, J. (2021). Preventing rather than Punishing: An Early Warning Model of Malfeasance in Public Procurement. *International Journal of Forecasting*, 37(1), 360-377.
- Gnaldi, M., & Del Sarto, S. (2024). Validating Corruption Risk Measures: A Key Step to Monitoring SDG Progress. *Social Indicators Research*.

- Gu, J., Jiang, X., Shi, Z., Tan, H., Zhai, X., Xu, C., Li, W., Shen, Y., Ma, S., Liu, H., Wang, S., Zhang, K., Lin, Z., Zhang, B., Ni, L., Gao, W., Wang, Y., & Guo, J. (2026). A survey on LLM-as-a-judge. *The Innovation*, 7(6), 101253. <https://doi.org/10.1016/j.xinn.2025.101253>
- Höppner, S., Baesens, B., Verbeke, W., & Verdonck, T. (2022). Instance-dependent cost-sensitive learning for detecting transfer fraud. *European Journal of Operational Research*, 297(1), 291-300.
- Katona, B., & Fazekas, M. (2024). *Hidden Barriers to Open Competition: Text-Based Corruption Strategies in Public Procurement*. GTI Working Paper GTI-WP/2024:01.
- Kuncheva, L., & Whitaker, C. (2003). Measures of Diversity in Classifier Ensembles and their Relationship with the Ensemble Accuracy. *Machine Learning*, 51, 181-207.
- Lima, W., Silva, V., & Lira, R. (2023). Methodology for automatic extraction of red flags in public procurement. *IEEE Latin America Transactions*.
- Lima, W., Silva, V., Silva, J., Lira, R., & Paiva, A. (2025). BidCorpus: A multifaceted learning dataset for public procurement. *Data in Brief*, 111202.
- Luna-Ortega, J. C., Cobos-Lozada, C. A., & Mendoza-Becerra, M. E. (2023). Modelo para definir índices de corrupción en convocatorias de contratación en Colombia basado en Big Data y procesamiento del lenguaje natural. *Revista Científica*, 46(1), 77-92.
- Lundberg, S. (2025). *Cartel detection in public procurement – Evaluation of five econometric methods*. Working Paper.
- Lyra, M. S., Curado, A., Damásio, B., Bação, F., & Pinheiro, F. L. (2021). Characterization of the firm–firm public procurement co-bidding network from the State of Ceará (Brazil) municipalities. *Applied Network Science*, 6(1), 1-10.

- Modrusan, N., Rabuzin, K., & Baca, M. (2020). Improving public sector efficiency using advanced text mining in the procurement process. *DATA 2020 - 9th International Conference on Data Science, Technology and Applications*.
- Nai, R., Sulis, E., Pasteris, P., Giunta, M., & Meo, R. (2023). Public tenders, complaints, machine learning and recommender systems: a case study in public administration. *Computer Law & Security Review*, 51, 105887.
- Nardo, M., Saisana, M., Saltelli, A., et al. (2008). *Handbook on Constructing Composite Indicators: Methodology and User Guide*. OECD/JRC. ISBN 978-92-64-04345-9.
- Niessen, J., et al. (2020). Anomaly Detection in Public Procurements using the Open Contracting Data Standard. *Seventh International Conference on eDemocracy eGovernment (ICEDEG)*, 127-132. IEEE.
- Open Contracting Partnership (2024). *Red Flags in Public Procurement: A Guide to Using Data to Detect and Mitigate Risks*. OCP.
- Pastor-Sanz, I., López-Iturriaga, F. J., & Hernando, A. (2024). A neural network approach for predicting corruption in public procurement. *Expert Systems with Applications*
- Potin, L., Figueiredo, R., Labatut, V., & Largeron, C. (2023). Pattern Mining for Anomaly Detection in Graphs: Application to Fraud in Public Procurement. *European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases*. Springer.
- Redroban Ortiz, C. L., Rivas-Tovar, L. A., Torres Maldonado, X. M., Almeida Alvarado, C. A., & Jaramillo Sangurima, L. V. (2024). Redes complejas como metodología para el control gubernamental en procesos de contratación pública en Ecuador. *Revista Española de la Transparencia*, (20), 215-249.

- Roh López, F. (2024). *Detección de comentarios acusatorios con indicios de corrupción en los procesos de compras públicas de Ecuador utilizando Procesamiento de Lenguaje Natural* [Tesis de maestría, Universidad San Francisco de Quito].
- Salazar, C., Pérez, J., & Gallego, J. (2024). VigIA: Prioritizing public procurement oversight with machine learning models and risk indices. *Data & Policy*, Cambridge University Press.
- Signor, R., Love, P. E. D., & Ballesteros-Pérez, P. (2024). Detecting bid rigging in public auctions for procuring infrastructure projects: formulating the reference scenario for decision-making. *Construction Management and Economics*.
- Torres Berrú, Y. M. (2023). *Minería de datos y texto para la detección de fraude en contratos públicos: Caso de estudio Sistema Oficial de Contratación Pública de Ecuador* [Tesis doctoral, Universidad de Salamanca].
- Torres-Berru, Y., & López-Batista, V. F. (2021). Data mining to identify anomalies in public procurement rating parameters. *Electronics*, 10, 2873.
- Torres-Berru, Y., López-Batista, V. F., & Hernando, A. (2023). A Data Mining Approach to Detecting Bias and Favoritism in Public Procurement. *Intelligent Automation & Soft Computing*, 36(3), 3501-3515.
- Tumer, K., & Ghosh, J. (1996). Error Correlation and Error Reduction in Ensemble Classifiers. *Connection Science*, 8(3-4), 385-404.
- Wang, Y., Chin, K., Poon, G., & Yang, J. (2009). Risk evaluation in failure mode and effects analysis using fuzzy weighted geometric mean. *Expert Systems with Applications*, 36(2), 1195-1207.
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. En A. Oh, T. Naumann, A. Globerson, K. Saenko,

M. Hardt y S. Levine (Eds.), Advances in Neural Information Processing Systems 36 (NeurIPS 2023).

ANEXO A: LINK DE GITHUB

https://github.com/GianTituana/proyecto_integrador.git